

vLLM与LMDeploy如何自定义对话模板

vLLM与LMDeploy如何自定义对话模板

- 1.vLLM聊天模板
2. LMDeploy自定义对话模板

1.vLLM聊天模板

为了使语言模型支持聊天协议，vLLM 要求模型在其 tokenizer 配置中包含聊天模板。聊天模板是一个 Jinja2 模板，用于指定角色、消息和其他特定于聊天的 token 如何在输入中编码。

可以在 [NousResearch/Meta-Llama-3-8B-Instruct 的示例聊天模板](#) 中找到

有些模型即使经过指令/聊天微调，也不提供聊天模板。对于这些模型，您可以在 `--chat-template` 参数中使用聊天模板的文件路径或字符串形式的模板手动指定其聊天模板。如果没有聊天模板，服务器将无法处理聊天，并且所有聊天请求都会出错。

```
vllm serve <model> --chat-template ./path-to-chat-template.jinja
```

vLLM 社区为流行的模型提供了一组聊天模板。您可以在 [examples](#) 目录下找到它们。

2. LMDeploy自定义对话模板

LMDeploy 支持两种添加对话模板的形式：

- 一种是利用现有对话模板，直接配置一个如下的 json 文件使用。

```
{
  "model_name": "your awesome chat template name",
  "system": "<|im_start|>system\n",
  "meta_instruction": "You are a robot developed by LMDeploy.",
  "eosys": "<|im_end|>\n",
  "user": "<|im_start|>user\n",
  "eoh": "<|im_end|>\n",
  "assistant": "<|im_start|>assistant\n",
  "eoa": "<|im_end|>",
  "separator": "\n",
  "capability": "chat",
  "stop_words": ["<|im_end|>"]
}
```

model_name 为必填项，可以是 LMDeploy 内置对话模板名（通过 `lmdeploy list` 可查阅），也可以是新名字。其他字段可选填。当 model_name 是内置对话模板名时，json 文件中各非 null 字段会覆盖原有对话模板的对应属性。而当 model_name 是新名字时，它会将其 `BaseChatTemplate` 直接注册成新的对话模板。其具体定义可以参考 [BaseChatTemplate](#)。

这样一个模板将会以下面的形式进行拼接。

```
{system}{meta_instruction}{eosys}{user}{user_content}{eoh}{assistant}
{assistant_content}{eoa}{separator}{user}...
```

在使用 CLI 工具时，可以通过 `--chat-template` 传入自定义对话模板，比如：

```
lmdeploy serve api_server internlm/internlm2_5-7b-chat --chat-template
${JSON_FILE}
```

也可以在通过接口函数传入，比如：

```
from lmdeploy import ChatTemplateConfig, serve

serve('internlm/internlm2_5-7b-chat',
      chat_template_config=ChatTemplateConfig.from_json('${JSON_FILE}'))
```

- 一种是以 LMDeploy 现有对话模板，自定义一个python对话模板类，注册成功后直接用即可。优点是自定义程度高，可控性强。下面是一个注册 LMDeploy 对话模板的例子：

```
from lmdeploy.model import MODELS, BaseChatTemplate

@MODELS.register_module(name='customized_model')
class CustomizedModel(BaseChatTemplate):
    """A customized chat template."""

    def __init__(self,
                 system='<|im_start|>system\n',
                 meta_instruction='You are a robot developed by LMDeploy.',
                 user='<|im_start|>user\n',
                 assistant='<|im_start|>assistant\n',
                 eosys='<|im_end|>\n',
                 eoh='<|im_end|>\n',
                 eoa='<|im_end|>',
                 separator='\n',
                 stop_words=['<|im_end|>', '<|action_end|>']):
        super().__init__(system=system,
                         meta_instruction=meta_instruction,
                         eosys=eosys,
                         user=user,
                         eoh=eoh,
                         assistant=assistant,
                         eoa=eoa,
                         separator=separator,
                         stop_words=stop_words)

from lmdeploy import ChatTemplateConfig, pipeline

messages = [{'role': 'user', 'content': 'who are you?'}]
pipe = pipeline('internlm/internlm2_5-7b-chat',
                chat_template_config=ChatTemplateConfig('customized_model'))
```

```
for response in pipe.stream_infer(messages):  
    print(response.text, end='')
```

在这个例子中，我们注册了一个 LMDeploy 的对话模板，该模板将模型设置为由 LMDeploy 创造，所以当用户提问模型是谁的时候，模型就会回答由 LMDeploy 所创。

参考资料：

[OpenAI 兼容服务器 — vLLM 文档](#)

[自定义对话模板 — lmdeploy](#)

